实验四 Milestone 1（M1）实验报告

一、实验目的

本次实验围绕 Milestone 1（M1）“数据清洗与 ELT 工程化交付”展开，目标是在前三周完成数据提取、清洗、聚合与漏斗分析的基础上，将原本偏脚本化的实现重构为可交付、可复现、可审计的工程化数据管道。具体目标如下：

1. 将分散在多个实验阶段中的数据处理逻辑模块化封装，形成标准的 `M1DataPipeline` 类。
2. 使用 Polars、DuckDB、Parquet 等现代工具完成亿级日志数据的高效处理，提升数据工程实践能力。
3. 借助 AI 辅助完成代码重构、代码审计与文档整理，提升程序的可维护性与工程化程度。
4. 通过 `benchmark.py` 对比 Pandas、Polars Eager、Polars Lazy 的性能差异，建立性能基准意识。
5. 通过 `m1_tester.py` 完成数据黑盒测试，验证最终交付文件 `m1_final_clean.parquet` 的字段完整性与业务正确性。
6. 编写完整实验报告，为后续 Milestone 2（M2）流批一体数据管道设计打下基础。

二、实验环境

2.1 运行环境

项目	环境
操作系统 / 终端	Windows + PowerShell
Python 版本	3.14.0
项目目录	`D:\Data_Analyze_test\test\test4`
Python 解释器	`d:/Data_Analyze_test/test/data_env/Scripts/python.exe`

2.2 主要依赖

依赖库	版本
Polars	1.38.1
DuckDB	1.5.0
Pandas	3.0.1
PyArrow	23.0.1
Matplotlib	3.10.8

2.3 核心文件

文件	作用
`run_m1_pipeline.py`	M1 主程序，封装 `M1DataPipeline` ，支持一键运行
`benchmark.py`	性能基准测试脚本
`m1_tester.py`	黑盒校验脚本
`README.md`	技术说明文档
`output/m1_final_clean.parquet`	最终交付数据文件
`output/pipeline_summary_chart.png`	管道分析汇总图
`output/benchmark_chart.png`	性能对比图

三、实验步骤

3.1 主程序工程化重构

根据实验要求，将前序实验中的清洗、去重、分析和输出逻辑统一封装到 `M1DataPipeline` 类中。主程序采用标准 ELT 三阶段结构：

- `extract()` ： 扫描分区 Parquet 文件并验证字段结构。
- `transform()` ： 完成逐分区统计、精密去重、漏斗分析、异常账号识别等核心计算。
- `load()` ： 输出图表和文本报告。

- `run()`：作为统一入口，串联全流程并记录日志。

同时在实现中加入了以下工程化特性：

- 使用 `logging` 统一输出阶段日志；
- 使用 `try-except` 捕获异常并中断流程；
- 使用 `Path` 管理路径，减少字符串路径拼接；
- 使用 `streaming collect`、`sink_parquet()` 和分桶去重来降低内存压力。

3.2 数据处理流程执行

主程序默认读取上级目录 `test2/clean_data_partitioned/` 下按 `behavior_type` 分区的 Parquet 文件，并将结果输出到 `output/` 目录。主要处理步骤如下：

1. 扫描分区数据并校验字段。
2. 对 `pv` 大分区采用 “按 `user_id` 哈希分 16 桶 + 逐桶 streaming 去重” 的两步方案。
3. 对 `buy`、`cart`、`fav` 等小分区直接进行 streaming 去重。
4. 合并所有去重结果，生成 `m1_final_clean.parquet`。
5. 基于最终输出文件计算行为分布、漏斗转化、异常账号等指标。
6. 输出图表、文本报告和性能对比结果。

3.3 AI 辅助代码审计

本次审计主要围绕以下几个维度展开：

1. **结构设计审计**：检查代码是否采用清晰的阶段划分，是否存在“主流程过长、职责混杂、难以维护”的问题。审计结果表明，程序采用了较规范的 `extract()`、`transform()`、`load()`、`run()` 四段式组织结构，主流程可读性较好，符合 ELT 管道的工程化表达方式。
2. **健壮性审计**：检查关键阶段是否具有异常捕获、日志记录和失败中断机制。代码在 `extract`、`transform`、`load` 三个阶段均设置了 `try-except`，并通过 `logging` 输出运行状态，便于定位错误来源，这一点明显优于普通实验脚本。
3. **路径与部署审计**：检查程序是否依赖固定目录布局。审计发现，`__main__` 中直接通过 `Path(__file__).parent.parent / "test2" / "clean_data_partitioned"` 构造输入路径，这虽然在当前实验目录下运行稳定，但迁移到其他机器或其他项目结构时仍然依赖相同目录层级，说明其可移植性还有提升空间。
4. **数据正确性审计**：检查去重规则、字段校验和业务规则过滤是否存在隐患。例如在 `extract()` 中，程序通过 `behavior_type=pv` 分区样本执行 `collect_schema()` 来验证字段结构，这种方式成本较低，但本质上属于“抽样校验”，如果其他分区字段异常而样本分区正常，理论上仍可能漏检。又如去重阶段使用 `group_by(...).agg(pl.first("category_id"))` 代替 `unique()`，能够兼容

streaming，但当同一主键对应多种 `category_id` 时，程序会保留第一条记录，这一策略在当前数据集上是可接受的，但从审计角度看应当被明确记录。

5. **性能与资源审计**：检查是否存在明显的内存风险。代码中使用了 `Polars Lazy API`、`engine="streaming"`、`sink_parquet()`、按 `user_id` 哈希分 16 桶等策略，说明作者对亿级数据处理中的内存瓶颈有较强意识；这一点也是本项目工程化价值最突出的部分之一。

通过 AI 辅助审计，当前程序的主要优点可以概括为：

- ELT 分层清晰，主流程职责明确，便于演示、维护和后续扩展；
- `Path`、`logging`、阶段化方法、图表输出等设计使代码具备了较好的工程化交付形态；
- 在大规模数据场景下主动采用 streaming 和分桶去重，能够有效降低内存压力；
- 对关键业务规则增加了 `buy_count <= pv_count` 的过滤逻辑，使最终交付文件更符合业务约束。

与此同时，审计也识别出几个值得在报告中明确记录的改进点：

- **路径配置仍偏硬编码**：当前数据源路径依赖固定相对目录，建议后续改为命令行参数、配置文件或环境变量注入，增强程序的跨目录部署能力。
- **Schema 校验仍可加强**：目前仅对单个 `pv` 分区做字段验证，建议扩展为对所有行为分区逐一校验，避免局部样本正常但全量分区不一致的情况。
- **去重保留策略应显式说明**：当前使用 `pl.first("category_id")` 作为重复记录保留值，虽然实现高效，但建议在代码注释或文档中解释“为什么保留第一条”以及“该策略对业务是否安全”。
- **日志细节仍可打磨**：例如 `_dedup_partition()` 中 “Step2 逐桶去重完成” 被连续记录了两次，属于不影响结果但会影响审计可读性的细节问题。
- **字体与环境兼容性问题**：图表字体配置中包含 `Arial Unicode MS`，在部分 Windows 或精简环境下可能触发字体缺失告警，建议提供更稳妥的字体回退方案。
- **报告结果需要最终产物复核**：`pipeline_report.txt` 属于运行期生成文本，若代码修改后未重新执行流程，文本内容可能与最新 Parquet 产物不一致，因此实验报告最终应以 `m1_final_clean.parquet` 自检结果和 `m1_tester.py` 黑盒测试结果为准。

总体来看，AI 在本项目中的作用并不是替代人工判断，而是帮助快速建立“检查清单”和“风险视角”。它能够提升发现问题、梳理问题和组织文档的效率，但最终哪些问题真实存在、是否影响结果、是否需要修复，仍然必须结合源码、运行日志、最终 Parquet 文件以及黑盒测试结果进行人工确认。这种“AI 初审 + 人工复核”的方式，比单纯依赖主观阅读代码更加系统，也更符合工程实践中的质量控制思路。

评审意见 / Final Verdict（同伴互评）

- 测试结论：`m1_tester.py` 测试通过（10/10 项全部通过）。最终交付物 `output/m1_final_clean.parquet` 约为 1,371.77 MB，包含 100,058,431 行记录，字段完整，并通过了业务规则校验与抽样去重验证，说明当前成果已经满足 M1 数据交换与质量验收要求。

- 核心闪光点：本次实现最突出的优点是代码重构较为模块化， `M1DataPipeline` 采用 `extract → transform → load → run` 的清晰分层，主流程组织规范；同时在亿级数据处理场景下结合 `Polars Lazy` 、 `streaming` 、 `sink_parquet()` 以及 `pv` 分区 16 桶去重策略，体现出较强的工程化和性能优化意识。此外，报告不仅完成了清洗交付，还补充了漏斗转化率、异常账号检测和图表化输出，使交付结果更完整、更具解释性。
- 最迫切的改进：当前输入路径仍依赖固定目录结构，迁移到其他环境时可移植性不足，后续更适合改为命令行参数、配置文件或环境变量注入；另外， `group_by + pl.first("category_id")` 的去重保留策略建议在文档中进一步说明业务合理性，同时清理重复日志输出，以提升代码的可审计性和后续维护性。

3.4 性能基准测试

运行 `benchmark.py` 对 Pandas、Polars Eager 和 Polars Lazy 三种方案进行行为分布统计性能对比。脚本对同一批分区文件重复测试 3 次，取最小值作为最终结果。

3.5 数据交换测试

使用教师提供的 `m1_tester.py` 对最终输出文件 `output/m1_final_clean.parquet` 进行黑盒测试，校验内容包括：

- 文件是否存在且可读取；
- 行数是否达到最低要求；
- 必要字段是否完整；
- `behavior_type` 值域是否合法；
- 是否存在全空行和负时间戳；
- 是否满足 `buy_count <= pv_count` 的业务规则；
- 抽样数据中是否存在重复记录。

四、实验结果

4.1 主程序结构与运行结果截图

下图展示了本次实验中 M1 管道主程序的主体结构与关键实现位置：

```python
class M1DataPipeline:
    """
    Milestone 1 数据处理管道。

    阶段:
        extract()   — 扫描分区 Parquet，验证 schema
        transform() — 逐分区去重落盘 → 扫输出做指标（全程 streaming）
        load()      — 生成图表 + 写报告
        run()       — 串联三阶段，计时，格式化汇总输出
    """
```

```python
    def run(self) -> None:
        wall_start = time.time()
        log.info("╔═══════════════════════════════════╗")
        log.info("║   M1DataPipeline  启动              ║")
        log.info("╚═══════════════════════════════════╝")
        log.info("数据源目录 : %s", self.source_dir.resolve())
        log.info("输出目录   : %s", self.output_dir.resolve())

        self.extract()
        metrics = self.transform()
        self.load(metrics)

        elapsed = time.time() - wall_start
        log.info("╔═══════════════════════════════════╗")
        log.info("║   全流程完成  总耗时 %.1f 秒          ║", elapsed)
        log.info("╚═══════════════════════════════════╝")


# ═══════════════════════════════════════════════════════
if __name__ == "__main__":
    _root = Path(__file__).parent.parent  # test4/ -> test/
    pipeline = M1DataPipeline(
        source_dir=str(_root / "test2" / "clean_data_partitioned"),
        output_dir=str(Path(__file__).parent / "output"),
    )
    pipeline.run()
```

```python
def extract(self) -> None:
    """验证 schema，返回各分区路径列表。"""
    log.info("=== EXTRACT 阶段开始 ===")
    try:
        # 用单个分区验证 schema，不扫全量
        sample_glob = (self.source_dir / "behavior_type=pv" / "*.parquet").as_posix()
        schema = pl.scan_parquet(sample_glob).collect_schema()
        required = {"user_id", "item_id", "category_id", "timestamp"}
        missing = required - set(schema.names())
        if missing:
            raise ValueError(f"缺少必要字段: {missing}")
        log.info("字段列表: %s", schema.names())
        log.info("EXTRACT 完成")
    except Exception as exc:
        log.error("EXTRACT 失败: %s", exc)
        raise
```

```python
def transform(self) -> dict:
    """
    内存安全转换:
      1. 逐分区统计原始行数
      2. 大分区(pv) hash 分桶去重，小分区直接去重，全部 sink_parquet
      3. 扫合并输出做指标统计（engine=streaming，group_by 替代 n_unique）
    """
    log.info("=== TRANSFORM 阶段开始 ===")
    metrics: dict = {}

    try:
        # ── 1. 逐分区统计原始行数 ──────────────────────────
        log.info("[1/4] 逐分区统计原始行数...")
        t0 = time.time()
        raw_count = 0
        part_counts: dict[str, int] = {}
```

```python
def load(self, metrics: dict) -> None:
    log.info("=== LOAD 阶段开始 ===")
    try:
        self._write_chart(metrics)
        self._write_report(metrics)
        log.info("LOAD 完成")
    except Exception as exc:
        log.error("LOAD 失败: %s", exc)
        raise
```

4.2 最终数据文件自检结果

m1_final_clean下载链接：https://github.com/pursue-pure/test4/blob/main/output/m1_final_clean.parquet

使用 Polars 对最终输出文件 `output/m1_final_clean.parquet` 进行自检，得到如下真实结果：

项目	结果
文件名	`m1_final_clean.parquet`
文件大小	1,438,404,436 Bytes（约 1,371.77 MB）
最终行数	100,058,431
字段列表	`user_id` 、 `item_id` 、 `timestamp` 、 `category_id` 、 `behavior_type`
Schema	`Int64` / `String` 组合，字段完整

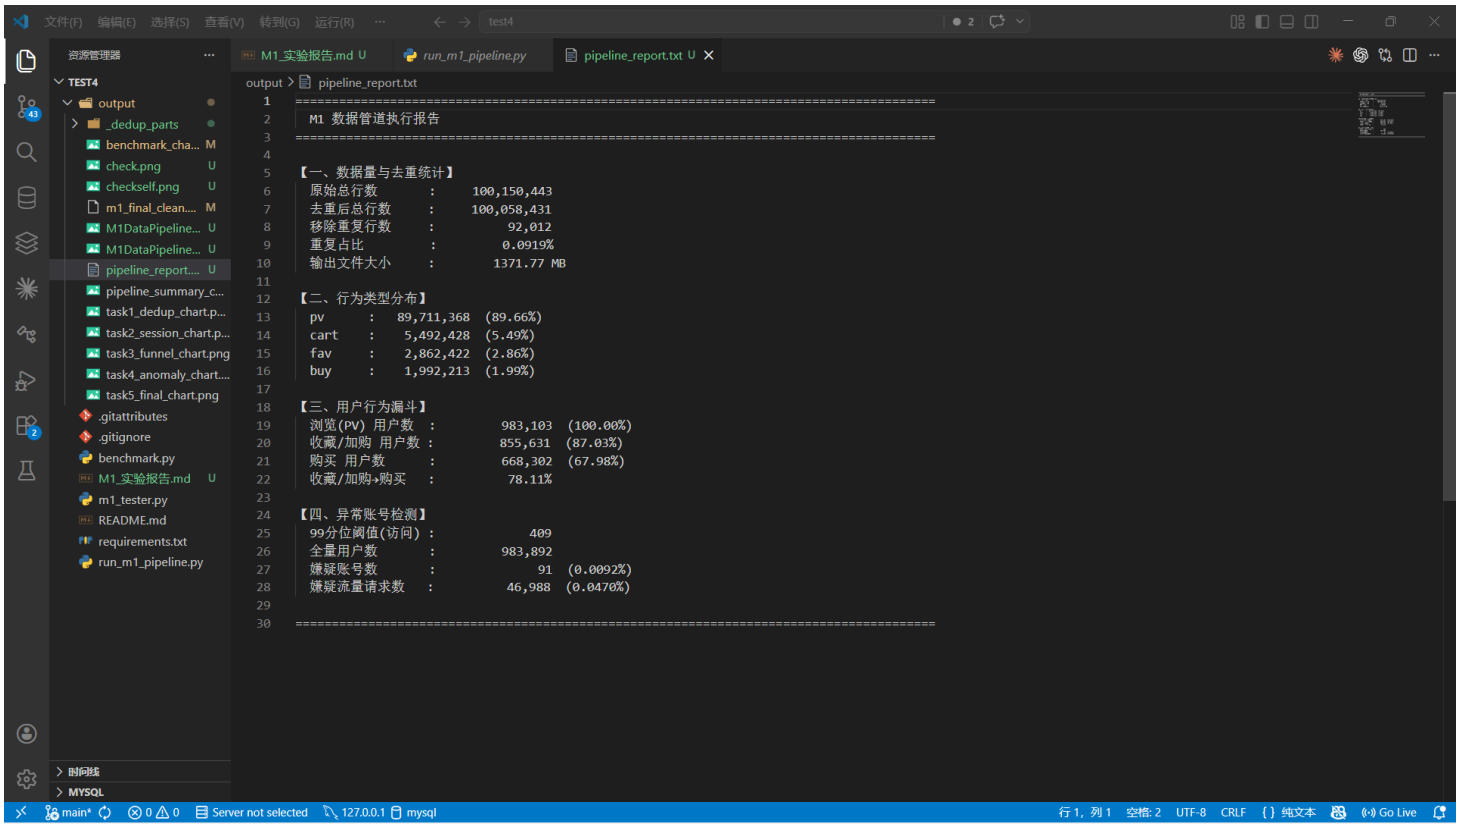

4.3 黑盒测试结果

对最终 Parquet 文件运行 `m1_tester.py` 后，得到如下结论：

- 文件存在且可访问：通过
- 文件可读取：通过

- 行数 > 0：通过
- 行数 >= 10,000,000：通过
- 必要字段完整：通过
- `behavior_type` 值域合法：通过
- 无全空行：通过
- `timestamp` 无负值：通过
- `buy_count <= pv_count` ：通过
- 抽样去重验证：通过

最终结论为：**10/10 项全部通过，数据质量符合 M1 基准要求。**

```
============================================================
  M1 数据校验报告
============================================================
  ✅ 文件存在且可访问  →  D:\Data_Analyze_test\test\test4\output\m1_final_clean.parquet
  ✅ 文件可读取  →  100,058,431 行
  ✅ 行数 > 0  →  实际行数: 100,058,431
  ✅ 行数 >= 10,000,000  →  实际: 100,058,431
  ✅ 必要字段完整  →  字段: ['behavior_type', 'category_id', 'item_id', 'timestamp', 'user_id']
  ✅ behavior_type 值域合法  →  值域: ['buy', 'cart', 'fav', 'pv']
  ✅ 无全空行  →  全空行数: 0
  ✅ timestamp 无负值  →  负值行数: 0
  ✅ 业务逻辑: buy_count <= pv_count (每用户)  →  违规用户数: 0
  ✅ 抽样去重验证 (100,000 行)  →  抽样重复行: 0

============================================================
  ✅ 校验结果: 10/10 项通过
  数据质量符合 M1 基准要求!
============================================================
```

4.4 核心业务指标

4.4.1 数据量与去重情况

指标	数值
原始总行数	100,150,443
去重后总行数	100,058,431
移除重复行数	92,012
重复占比	0.0919%

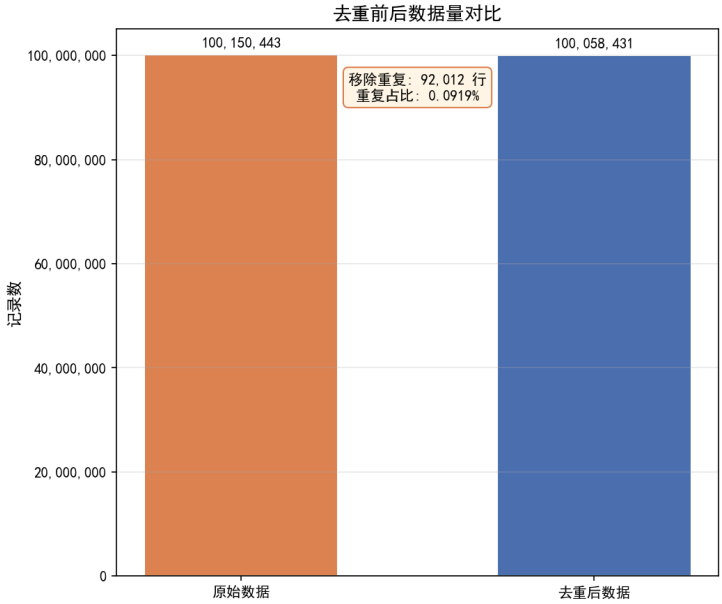

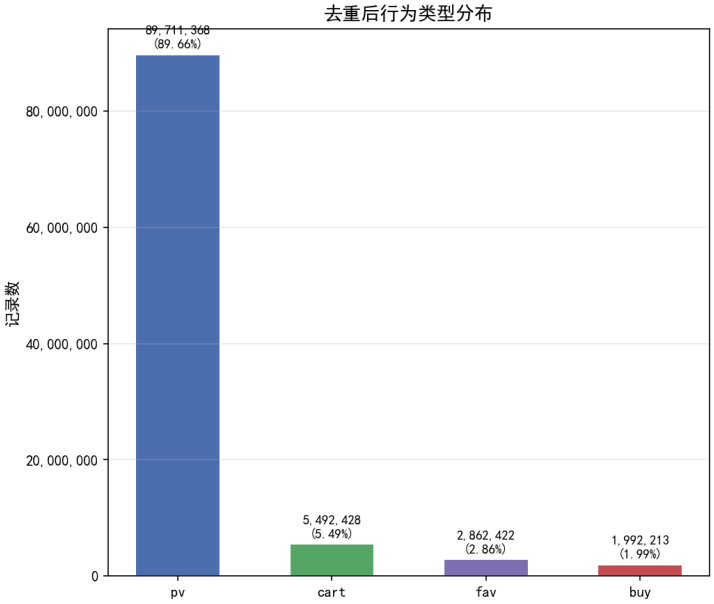

4.4.2 行为类型分布

行为类型	行数	占比
pv	89,711,368	89.66%
cart	5,492,428	5.49%
fav	2,862,422	2.86%
buy	1,992,213	1.99%

4.4.3 用户行为漏斗

漏斗阶段	用户数	转化率
浏览（PV）	983,103	100.00%
收藏 / 加购	855,631	87.03%
购买	668,302	67.98%
收藏/加购 → 购买	-	78.11%

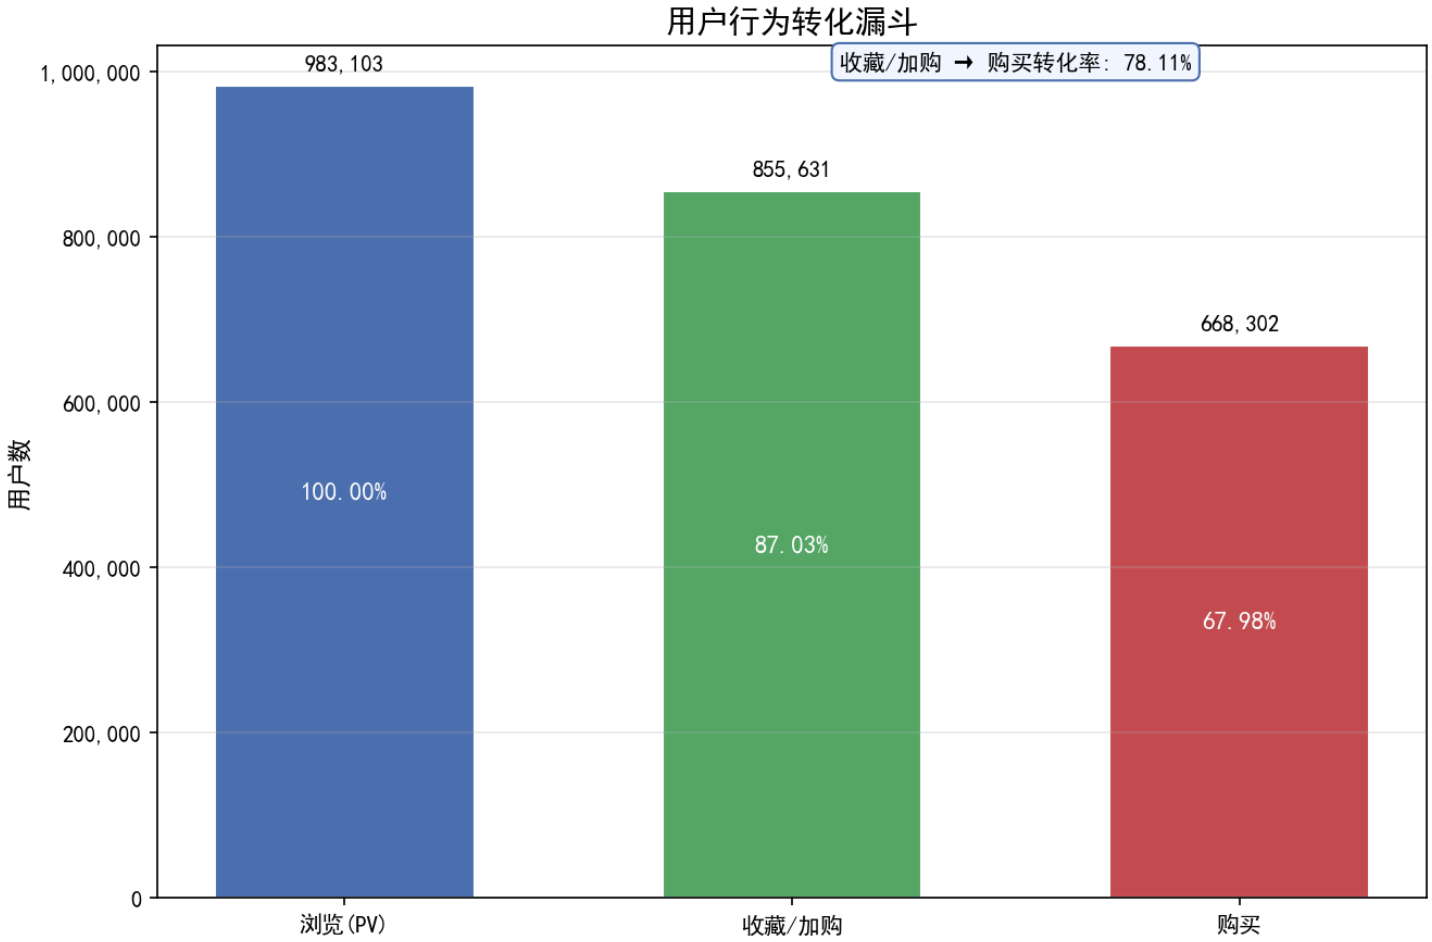

4.4.4 异常账号检测结果

指标	数值
99 分位阈值	409
全量用户数	983,892
嫌疑账号数	91
嫌疑账号占比	0.0092%
嫌疑流量请求数	46,988
嫌疑流量占比	0.0470%

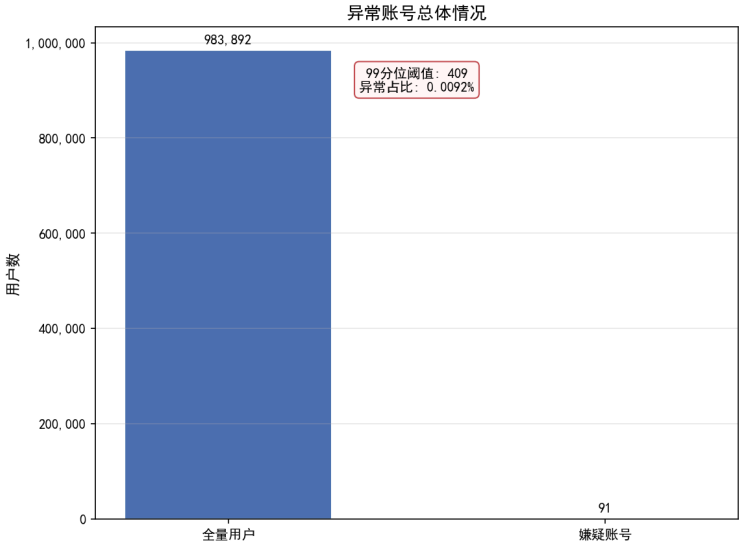
异常账号总体情况
983,892
99分位阈值: 409
异常占比: 0.0092%
91
用户数
全量用户
嫌疑账号

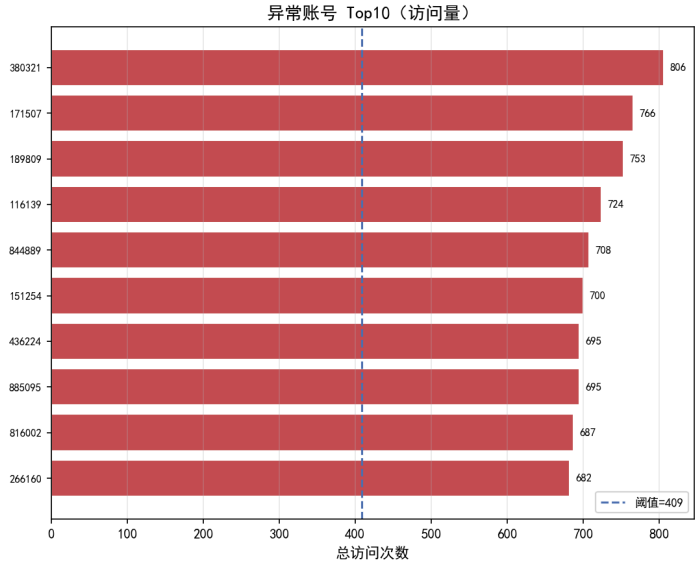
异常账号 Top10（访问量）
380321
171507
189809
116139
844889
151254
436224
885095
816002
266160
806
766
753
724
708
700
695
695
687
682
阈值=409
总访问次数

4.4.5 最终成果总览图

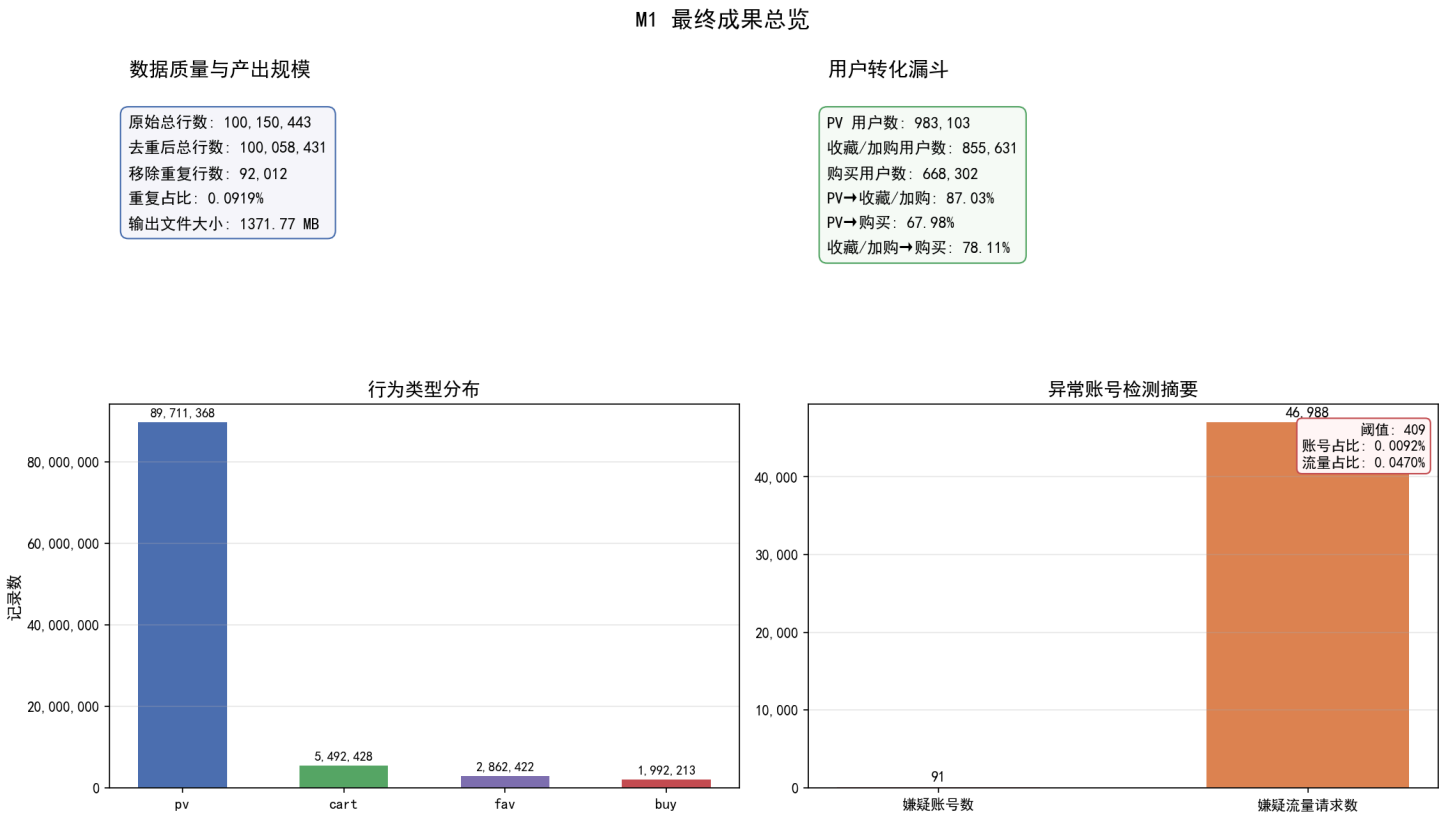
M1 最终成果总览
数据质量与产出规模
原始总行数: 100,150,443
去重后总行数: 100,058,431
移除重复行数: 92,012
重复占比: 0.0919%
输出文件大小: 1371.77 MB
用户转化漏斗
PV 用户数: 983,103
收藏/加购用户数: 855,631
购买用户数: 668,302
PV→收藏/加购: 87.03%
PV→购买: 67.98%
收藏/加购→购买: 78.11%
行为类型分布
89,711,368
5,492,428
2,862,422
1,992,213
记录数
pv
cart
fav
buy
异常账号检测摘要
46,988
阈值: 409
账号占比: 0.0092%
流量占比: 0.0470%
91
嫌疑账号数
嫌疑流量请求数

4.4.6 管道汇总图

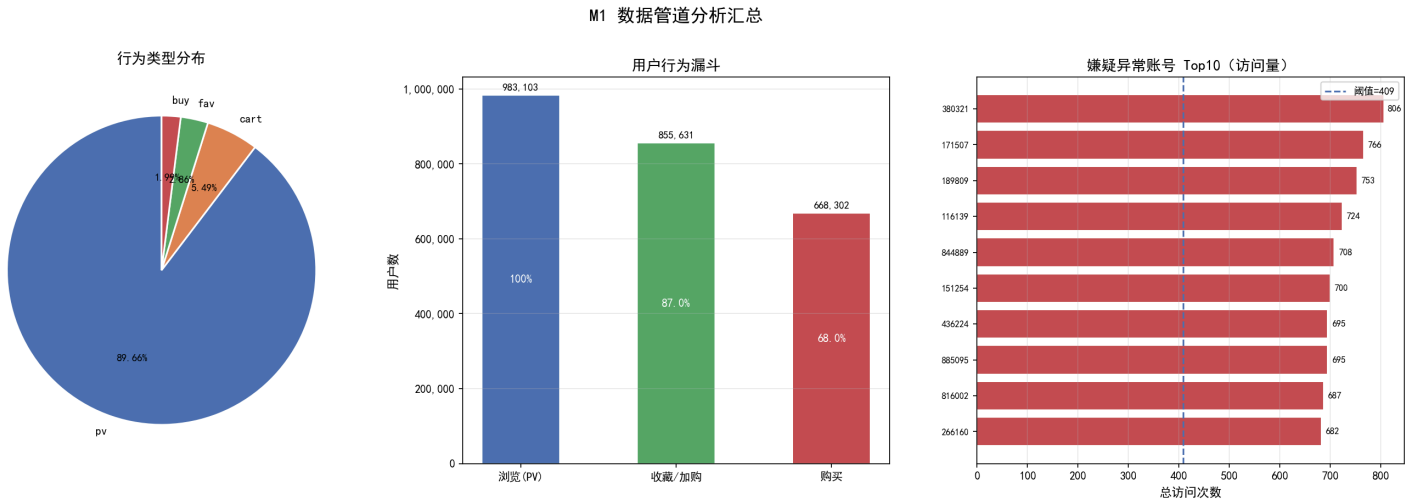

4.5 性能基准结果

运行 `benchmark.py` 后得到如下结果：

方案	耗时（秒）	相对 Pandas 加速比
Pandas Eager	18.464	1.00x
Polars Eager	1.291	14.30x
Polars Lazy	0.414	44.62x

```
PS D:\Data_Analyze_test\test\test4> & d:/Data_Analyze_test/test/data_env/Scripts/python.exe d:/Data_Analyze_test/test/test4/benchmark.py
找到 4 个分区文件，开始基准测试（每方案重复 3 次）...

  [1/3] Pandas Eager ...
        完成: 18.464s
  [2/3] Polars Eager ...
        完成: 1.291s
  [3/3] Polars Lazy ...
        完成: 0.414s

====================================================
  性能基准对比结果（取 3 次最小值）
====================================================
  方案                      耗时(s)     相对Pandas加速比
----------------------------------------------------
  Pandas Eager            18.464          1.00x
  Polars Eager             1.291         14.30x
  Polars Lazy              0.414         44.62x
====================================================
```

结果表明，在该实验的数据规模下，Polars Lazy 相较 Pandas Eager 具有非常明显的性能优势，说明 Lazy API、列式扫描和延迟执行对大规模行为日志处理非常有效。

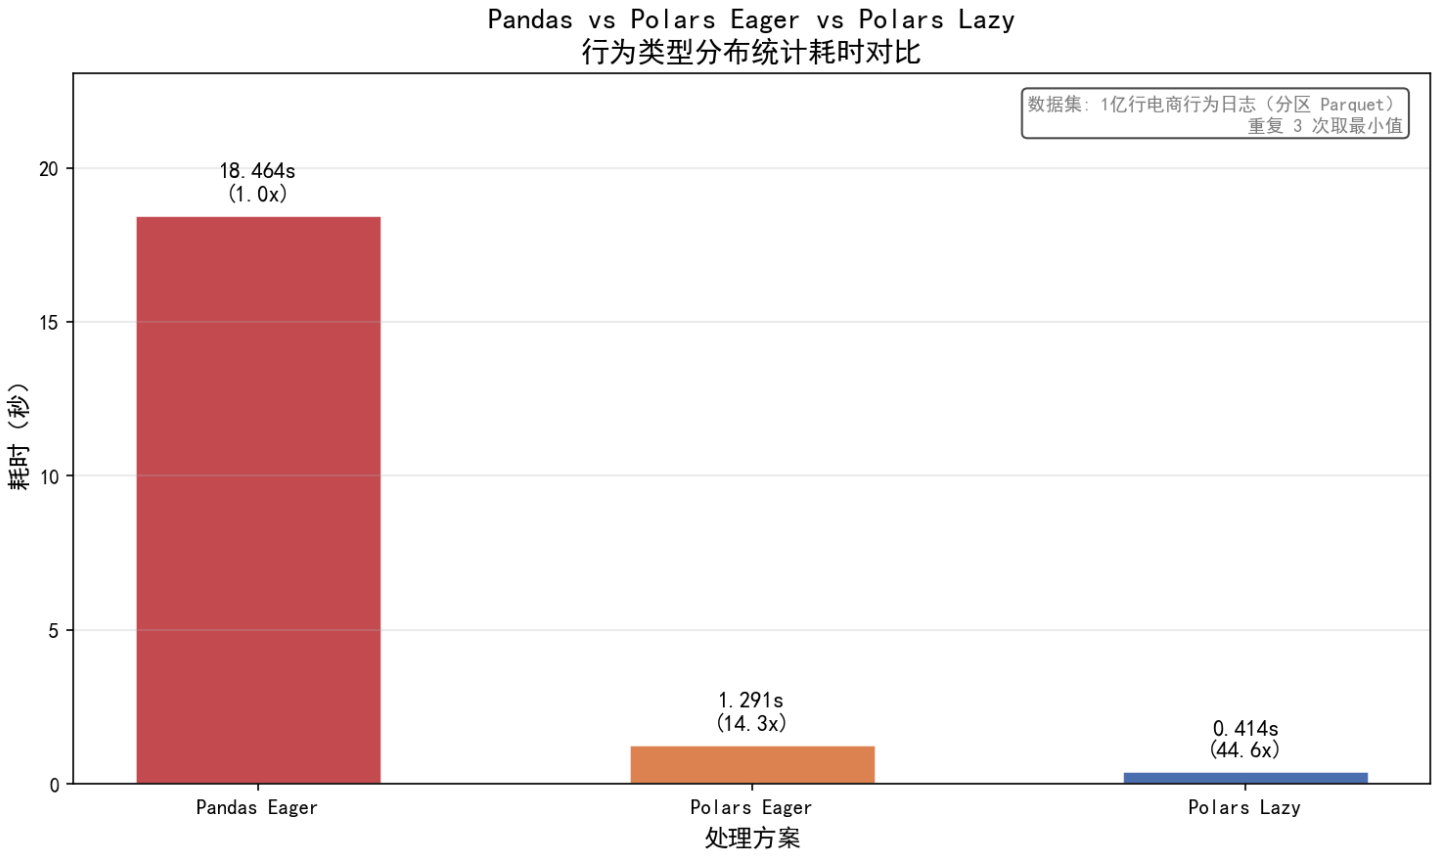

五、实验总结与反思

5.1 从“能跑通的代码”到“工程级代码”的权衡

本次实验让我更清楚地意识到，“能跑通”与“工程级”之间真正的差距，并不只是代码长短或语法是否正确，而是在可维护性、可复现性、可审计性和异常场景处理上的系统性投入。前期脚本虽然已经能够完成清洗和分析任务，但逻辑分散、入口不统一，出了问题也很难快速定位。AI 在这里帮助我跨过的第一个障碍，是把原本零散的处理逻辑重新组织成 `M1DataPipeline` 这一明确的工程骨架，并进一步拆分为 `extract()` 、 `transform()` 、 `load()` 、 `run()` 四个阶段，让整个流程从“顺着往下写的脚本”变成“可以讲清楚、可以维护、可以复用的管道”。

第二个障碍，是把原本只关注结果的代码，推进到更重视质量控制的代码。AI 辅助我补全了许多过去容易忽略但在工程里很重要的细节，例如为关键阶段增加更统一的日志输出、使用 `try-except` 做阶段级错误捕获、用 `Path` 统一管理输入输出路径，以及通过注释、文档字符串和报告说明来增强代码的可读性。

第三个障碍，是性能与可实现性的平衡。面对亿级数据时，单纯“能算出来”并不够，还要考虑内存是否可控、流程是否能稳定跑完。AI 在这方面帮助我更快梳理出合适的工程策略，例如结合

`Polars Lazy`、`engine="streaming"`、`sink_parquet()`、按 `user_id` 哈希分桶等方式，把重点从“写一段看起来正确的处理逻辑”转向“写一段在真实数据规模下也能落地的处理逻辑”。

5.2 对“AI 黑盒”的警惕：逻辑偏差与技术债修正

虽然 AI 在重构中提供了很大帮助，但它带来的风险同样真实存在。本项目并没有复杂到“会话切割逻辑”那样的场景，但仍然出现过“解释看起来合理、实际却需要重新核验”的偏差。最典型的例子，是中间文本报告 `pipeline_report.txt` 的内容并不能天然代表最终交付结果；如果代码改动后没有重新跑完整流程，文本报告就可能保留旧统计值。换句话说，AI 在整理代码和文档时，容易默认中间结果与最终产物始终一致，而这一点在真实工程里并不能直接成立。

除此之外，AI 辅助重构后的代码里也存在一些“短期可用、长期需要说明”的技术债。例如，`extract()` 目前只用 `behavior_type=pv` 分区样本做 `collect_schema()` 校验，这种做法运行成本低，但本质上是抽样校验；再如，去重逻辑中使用 `group_by(...).agg(pl.first("category_id"))` 代替 `unique()`，虽然更适合 streaming 执行，但它隐含了“保留第一条记录”的业务假设，这种假设如果不写清楚，后续维护者就很难判断其合理性。还有像重复日志输出这样的细节，看似不影响结果，却会削弱代码的可审计性。

我发现并修正这些由 AI 带来的“技术债”，主要依靠三种方法。第一，回到真实源码逐段核对，而不是只接受 AI 给出的自然语言总结；第二，把最终 Parquet 文件和 `m1_tester.py` 的结果作为事实基准，而不是把中间文本或解释性输出当作最终真相；第三，在实验报告中显式记录这些限制和假设，把“暂时未彻底消除的问题”从隐藏风险转化为可追踪的问题。这个过程让我认识到，AI 可以帮助我更快生成方案，但不能替代我为结果负责。

5.3 评审的价值：`m1_tester.py` 暴露出的盲点

`m1_tester.py` 对我最大的帮助，不只是“证明程序通过了测试”，而是逼着我看到自己原本没有系统关注的盲点。以前我更容易把注意力放在流程能否跑通、图表是否生成、指标是否好看上，但测试脚本提醒我，交付物首先是一个需要满足明确约束的数据产品，而不是一段“看起来没问题”的代码。像字段是否完整、`behavior_type` 值域是否合法、是否存在全空行、时间戳是否为负、最终文件是否达到最低数据规模，这些内容如果不通过独立脚本检查，在人工观察阶段其实很容易被忽略。

更重要的是，`m1_tester.py` 还让我意识到，有些问题并不会直接体现在汇总指标里。例如，`buy_count <= pv_count` 这样的业务规则约束，单看行为分布图和漏斗图并不一定能发现；抽样去重验证也说明，最终总行数正确并不等于数据内部一定不存在重复记录。这些都是我在只关注“主流程是否结束”和“输出图是否正常”时容易忽视的部分。

因此，这次交叉验证带来的最大收获，是让我重新理解了“评审”的价值。评审并不是在代码完成后额外附加的一步，而是帮助开发者识别盲点、补足自信偏差的重要机制。即使本次 `m1_tester.py` 最终 10/10 全部通过，它依然暴露出我原先更偏重功能和性能、却对交付约束检查不够系统的习惯。今后如

果继续做更复杂的数据管道，我会把这类独立测试和交叉验证更早纳入开发流程，而不是等到最后再补。

六、实验收获

通过本次实验，我在以下几个方面获得了较系统的提升：

1. 学会了将大数据处理脚本工程化封装为类和阶段化方法，理解了 ELT 管道的标准组织方式。
2. 掌握了 Polars Lazy API、streaming collect、 `sink_parquet()` 等大规模数据处理优化思路。
3. 理解了分桶去重、按分区处理等策略在亿级数据场景中的实际价值。
4. 通过性能基准测试量化感受到 Polars 相对 Pandas 的性能优势，增强了性能评估意识。
5. 理解了黑盒测试和数据交换测试在数据工程中的重要性，知道交付物必须接受独立校验。
6. 体会到 AI 在重构、审计、文档撰写中的辅助价值，同时也意识到必须保持人工复核，避免被旧结果或中间结果误导。