M1 数据清洗与 ELT 工程化管道

项目概况

本项目为《大数据分析》课程 Milestone 1（M1）的工程化交付成果，目标是将阿里巴巴 UserBehavior 电商行为日志从原始 CSV 处理为可用于后续分析的高质量 Parquet 数据集，并形成可复现、可审计、可交付的工程化数据管道。

数据集包含四类核心行为：

- `pv`： 浏览
- `fav`： 收藏
- `cart`： 加购
- `buy`： 购买

本项目最终交付的核心产物为：

- `output/m1_final_clean.parquet`
- `output/pipeline_summary_chart.png`
- `output/benchmark_chart.png`
- `output/pipeline_report.txt`

当前真实产出结果如下：

项目	当前结果
原始总行数	100,150,443
最终行数	100,058,431
移除重复行数	92,012
重复占比	0.0919%
最终文件大小	1,371.77 MB
最终 Schema	`user_id`、`item_id`、`timestamp`、`category_id`、`behavior_type`

数据流转图

第一部分：数据准备与管道入口

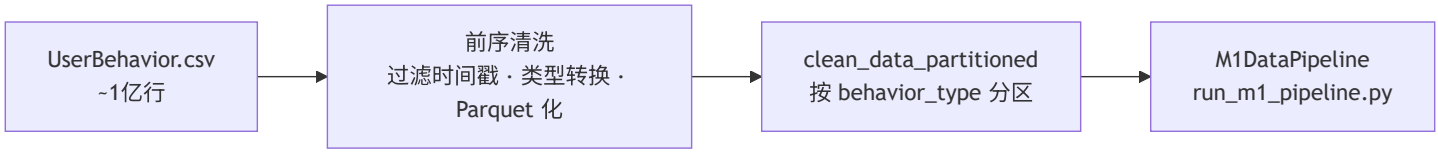

第二部分：M1 管道处理与结果输出

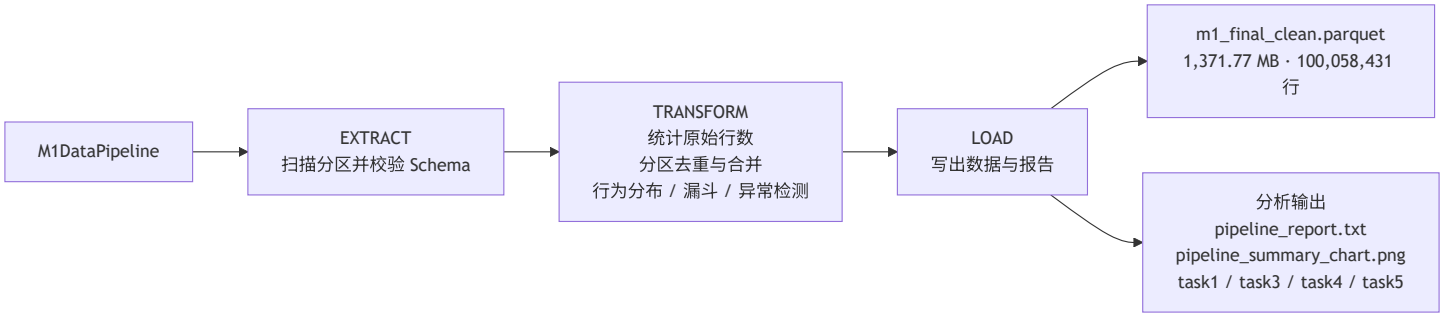

核心技术栈

技术	当前版本	用途
Python	3.14.0	项目运行环境
Polars	1.38.1	主处理引擎，负责 Lazy API 与 streaming 计算
PyArrow	23.0.1	Parquet 读写后端
DuckDB	1.5.0	前序阶段数据探查与 SQL 处理
Pandas	3.0.1	基准测试对照组
Matplotlib	3.10.8	图表绘制

工程结构

M1DataPipeline 类职责

```
M1DataPipeline
├── __init__(source_dir, output_dir)   # 初始化路径，清理临时目录
├── extract()                          # 验证输入分区 schema
├── _dedup_partition(bt)               # 单分区去重逻辑
├── transform()                        # 去重 + 统计 + 漏斗 + 异常检测
├── load(metrics)                      # 输出图表与文本报告
└── run()                              # 一键串联全流程
```

内存优化策略

处理 1 亿级行为日志时，内存控制是核心问题。本项目采用如下策略：

策略	说明
PV 大分区分桶去重	对 `pv` 分区按 `user_id hash % 16` 分桶，再逐桶 streaming 去重，避免单次建立超大去重状态
`group_by + agg(first)` 替代 `unique()`	因 Polars streaming engine 对 `unique()` 支持有限，使用等价写法提高可执行性
`engine="streaming"`	大部分统计过程使用 streaming 模式，降低峰值内存
`sink_parquet()` 中间落盘	先写中间结果，再基于最终输出做指标统计，减少重复 collect
分区独立处理	`buy/cart/fav` 小分区直接独立去重，避免不必要的复杂路径

核心分析指标

数据量与去重

指标	数值
原始总行数	100,150,443
去重后总行数	100,058,431
移除重复行数	92,012
重复占比	0.0919%
最终文件大小	1,371.77 MB

行为类型分布

这些数值直接来自最终 `m1_final_clean.parquet` 的真实统计结果：

行为类型	行数	占比
pv（浏览）	89,711,368	89.66%
cart（加购）	5,492,428	5.49%
fav（收藏）	2,862,422	2.86%
buy（购买）	1,992,213	1.99%

用户行为转化漏斗

漏斗阶段	用户数	转化率（相对 PV）
浏览（PV）	983,103	100.00%
收藏 / 加购	855,631	87.03%
购买	668,302	67.98%
收藏/加购 → 购买	-	78.11%

异常账号检测

检测逻辑：

- 用户访问量超过 99 分位阈值
- 且该用户不存在非 `pv` 行为

指标	数值
99 分位阈值（访问次数）	409
全量用户数	983,892
嫌疑账号数	91
嫌疑账号占比	0.0092%
嫌疑流量请求数	46,988
嫌疑流量占比	0.0470%

数据交换测试（Data Swap Testing）

本项目使用教师提供的 `m1_tester.py` 对最终交付的 `m1_final_clean.parquet` 进行了黑盒校验。当前真实测试结果为：

- 文件存在且可访问：通过
- 文件可读取：通过
- 行数 > 0：通过
- 行数 >= 10,000,000：通过
- 必要字段完整：通过
- `behavior_type` 值域合法：通过
- 无全空行：通过
- `timestamp` 无负值：通过
- `buy_count <= pv_count` ：通过
- 抽样去重验证：通过

最终结论：**10/10 项全部通过，数据质量符合 M1 基准要求。**

性能基准对比

`benchmark.py` 对 Pandas、Polars Eager、Polars Lazy 三种方案进行了对比，当前真实运行结果如下：

方案	耗时（秒）	相对 Pandas 加速比
Pandas Eager	23.528	1.00x
Polars Eager	2.045	11.51x
Polars Lazy	0.539	43.67x

可以看到，在该实验的数据规模下，Polars Lazy 相比 Pandas 具有明显性能优势，说明列式扫描与延迟执行非常适合大规模行为日志处理。

AI 指令示例

以下提示词可用于让 AI 辅助生成本项目的技术文档：

```
请根据我的 M1 管道代码，帮我写一份详细的技术文档。请用 Mermaid 或 PlantUML 语法画出数据流转图，并用表
```

输出文件说明

当前 `output/` 目录中与报告直接相关的真实文件包括：

文件	说明
`m1_final_clean.parquet`	最终交付的清洗结果
`pipeline_report.txt`	文本版执行报告
`task1_dedup_chart.png`	去重与行为分布图
`task3_funnel_chart.png`	漏斗分析图
`task4_anomaly_chart.png`	异常账号检测图

文件	说明
`task5_final_chart.png`	最终 KPI 总览图
`pipeline_summary_chart.png`	综合汇总图
`benchmark_chart.png`	性能基准图
`checkself.png`	黑盒测试通过截图

目录结构

```
test4/
├── run_m1_pipeline.py
├── benchmark.py
├── m1_tester.py
├── README.md
├── requirements.txt
└── output/
    ├── m1_final_clean.parquet
    ├── pipeline_report.txt
    ├── task1_dedup_chart.png
    ├── task3_funnel_chart.png
    ├── task4_anomaly_chart.png
    ├── task5_final_chart.png
    ├── pipeline_summary_chart.png
    ├── benchmark_chart.png
    └── checkself.png
```

快速开始

安装依赖

```
pip install -r requirements.txt
```

运行主程序

```
python run_m1_pipeline.py
```

运行性能基准

```
python benchmark.py
```

运行黑盒测试

Windows PowerShell 下建议开启 UTF-8 输出，避免 ✅/❌ 字符编码报错：

```
$env:PYTHONUTF8='1'
python m1_tester.py .\output\m1_final_clean.parquet
```

数据来源

阿里巴巴 UserBehavior 数据集。当前项目读取的是前序实验已经完成清洗和分区的 Parquet 数据，路径位于：

```
../test2/clean_data_partitioned/
```

数据按 `behavior_type` Hive 风格分区组织，便于在 M1 阶段进行分区扫描、独立去重和后续聚合分析。